CRISP-DM aplicado: clasificación de calidad y tamaño de frutas

Fuentes de datos

Kaggle: Fruit Quality Classification
(imágenes individuales por calidad)

Imágenes mixed_quality
(varias frutas por foto, se separan)

1. Comprensión del negocio

- Pérdidas poscosecha y selección manual
- Salidas: calidad (buena/regular/mala) y tamaño
- Éxito: F1 macro, recall de 'mala', < 2 s
- Ética e impactos desde el inicio

2. Comprensión de los datos

- EDA del dataset de Kaggle: frutas y clases
- Hallazgo: fondo y resolución distintos por clase
- mixed_quality: varias frutas por foto
- Elección de frutas y definición de clases

3. Preparación de los datos

- Segmentación: Otsu (ΔE y saturación) + GrabCut
- mixed: watershed (transformada de distancia)
- Tamaño: d = 2·√(A/π), normalizado
- Características de color, textura y forma

ajustar clases

¿cumple los criterios de éxito?

errores de segmentación o de características

6. Despliegue

- App Streamlit: cargar imagen o cámara
- Muestra calidad, confianza y tamaño
- Aviso de revisión humana si la confianza es baja
- Tiempo de inferencia medido

5. Evaluación

- Test interno estratificado (Kaggle)
- Test externo: fotos propias del equipo
- Matriz de confusión, curvas, sobreajuste
- Error del tamaño contra el diámetro en cm

reajustar modelos

4. Modelado

- Línea base: regresión logística
- SVM (RBF) y Random Forest + GridSearchCV
- CNN simple desde cero (Keras)
- Pesos por clase y aumentación

prueba externa

Fotos propias del equipo
(etiquetas de calidad + diámetro en cm)

Continuas: flujo principal
Punteadas: iteraciones entre fases